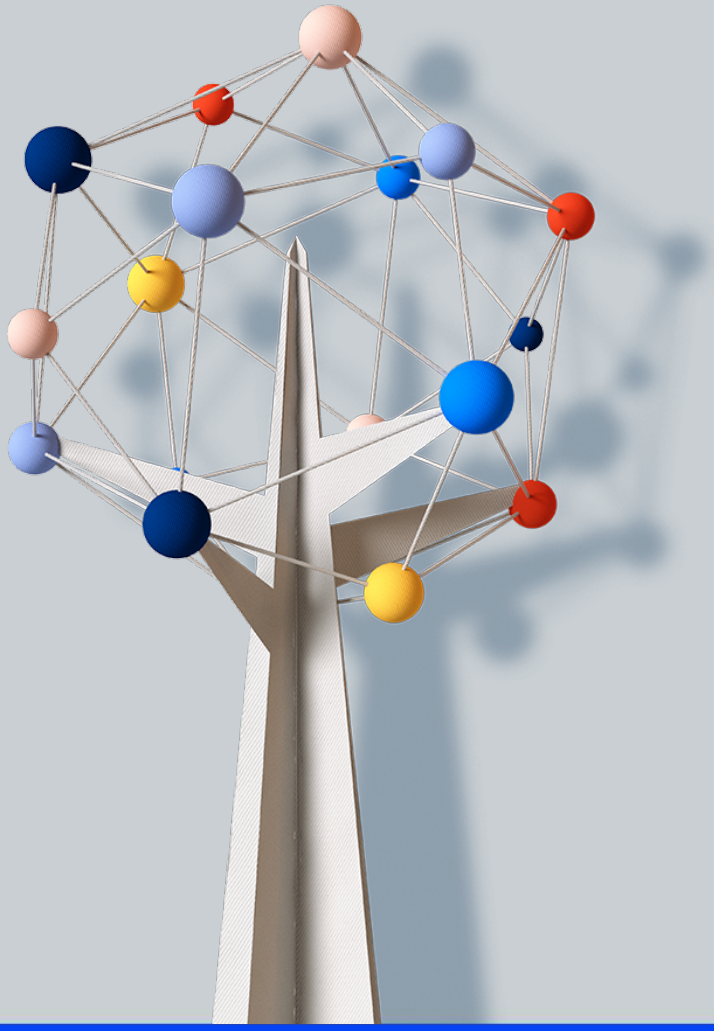
cegid Academy



AiDAPT04

cegid

Objetivos	Recolha de dados da web (web scraping e/ou consumo de APIs) Importação e exploração inicial de dados Análise exploratória e visualização Limpeza e preparação de dados Engenharia de variáveis Modelação preditiva e interpretação de resultados
Recursos	Linguagem Python Jupyter Notebook Bibliotecas sugeridas: pandas, numpy, matplotlib, seaborn, scikit-learn (e requests, BeautifulSoup para a recolha de dados)

B. Contexto

Neste projeto, cada grupo escolhe um tema e recolhe os próprios dados a partir da web. O objetivo é percorrer um ciclo completo de ciência de dados, seguindo a metodologia CRISP-DM: compreender o problema, recolher e explorar os dados, prepará-los, construir modelos preditivos e avaliar criticamente os resultados.

Pretende-se que, no final, o grupo seja capaz de identificar padrões relevantes e retirar conclusões úteis para apoio à decisão, consolidando as competências de recolha (web scraping e APIs), tratamento, análise e modelação de dados. O trabalho resulta num projeto autónomo, único de cada grupo, ideal para portfólio.

C. Recolha e conjunto de dados

Cada grupo constroi o seu próprio dataset, recolhendo os dados a partir de uma fonte online através de web scraping e/ou do consumo de APIs e bases de dados.. O grupo escolhe um tema e uma fonte, recolhe os dados e guarda-os num ficheiro CSV (dados brutos), que servirá de base a todo o trabalho.

Exemplos de temas e fontes *(apenas exemplos — os grupos podem escolher outros):*

Tema	Fonte(s) sugerida(s)		O que recolher	Pergunta / objetivo de análise
Emprego e mercado de trabalho	Arbeitnow Job Board API — arbeitnow.com/api/job-board-api (JSON, sem chave) e páginas HTML de arbeitnow.com		Título, empresa, localização, remoto (sim/não), tecnologias/tags, tipo de contrato, data	Que competências são mais procuradas? Prever se uma vaga é remota (classificação).
Países e indicadores	scrapethissite.com/pages/simple (sandbox) · restcountries.com (API) · tabelas da Wikipédia		País, capital, população, área, região	Comparar densidade por região; prever a região a partir dos indicadores.
Desporto (estatística	scrapethissite.com/pages/forms (com formulários e		Equipa, ano, vitórias,	Evolução do desempenho; prever

Tema	Fonte(s) sugerida(s)		O que recolher	Pergunta / objetivo de análise
s de equipas)	paginação) · tabelas da Wikipédia		derrotas, % de vitórias, golos	se foi uma época "vencedora".
Cinema e cultura	scrapethissite.com/pages/ajax-javascript (conteúdo carregado por JavaScript) · listas da Wikipédia		Filme, ano, nomeações, prémios	Tendências por década; prever se um filme foi premiado.
Livros e catálogos	books.toscrape.com (catálogo realista) · Open Library / gutendex.com (API)		Título, preço, classificação, categoria, disponibilidade	Preço médio por categoria; prever a classificação ou o preço (regressão).
Clima e ambiente	Open-Meteo — open-meteo.com (API grátis, sem chave, dados históricos e previsão)		Temperatura, precipitação, vento por data e local	Sazonalidade e séries temporais; prever a temperatura.

Nota: *estes são apenas exemplos. Cada grupo pode escolher um tema e uma fonte completamente diferentes (outro site ou outra API), desde que respeite as regras de ética abaixo e obtenha validação prévia do formador.*

Regras de ética e boas práticas

A recolha de dados da web tem de ser feita de forma responsável e legal. Todos os grupos devem cumprir:

- Ler e respeitar o ficheiro robots.txt do site e os respetivos Termos de Utilização.
- Preferir sempre uma API oficial quando esta existe — é mais estável, mais rápida e legalmente mais segura do que retirar informação do HTML.
- Recolher apenas dados públicos e para fins pedagógicos, sempre que possível, e não recolher dados pessoais nem conteúdos protegidos por direitos de autor.
- Guardar sempre os dados brutos recolhidos, para garantir a reprodutibilidade do trabalho.

Requisitos mínimos do conjunto de dados

- Os dados têm de ser recolhidos pelo próprio grupo (será fornecido um CSV pelo formador no caso do grupo sentir dificuldade na recolha de dados).
- Pelo menos 100 registos (linhas).
- Pelo menos 5 variáveis, incluindo no mínimo 2 numéricas e 1 categórica.
- Guardar tanto os dados brutos como os dados tratados.

D. Etapas

O projeto segue a metodologia CRISP-DM, organizada nas seguintes fases:

1. Business Understanding

Nesta fase, os formandos devem compreender o problema, escolher o tema do projeto e enquadrar o objetivo no contexto pretendido.

Objetivos desta fase:

- Escolher o tema do projeto e a pergunta de análise.
- Compreender o problema em estudo.
- Identificar a variável-alvo.
- Perceber o que significa, na prática, prever essa variável.
- Refletir sobre a utilidade prática deste tipo de análise para apoio à decisão.

2. Data Understanding

Nesta fase, os formandos recolhem os próprios dados a partir de uma fonte online (web scraping ou API) e exploram o conjunto de dados obtido, compreendendo a sua estrutura, qualidade e conteúdo.

Objetivos desta fase:

- Escolher a fonte de dados e recolher os dados por web scraping e/ou API, respeitando as regras de ética e boas práticas (secção C).
- Guardar os dados brutos recolhidos, garantindo a reprodutibilidade.
- Conhecer o dataset construído.
- Identificar a estrutura dos dados.
- Avaliar a qualidade inicial dos dados.
- Analisar o comportamento da variável-alvo e das variáveis explicativas.

3. Data Preparation

Nesta fase, os formandos devem preparar os dados para posterior modelação.

Objetivos desta fase:

- Corrigir problemas de qualidade dos dados (dados em falta, inconsistências, duplicados).
- Processar strings e datas e normalizar valores.
- Transformar os dados para os tornar adequados aos algoritmos (codificação de variáveis categóricas, colunas derivadas, escalonamento).
- Construir o conjunto final de dados para treino e teste.

4. Modelling

Nesta fase, os formandos devem treinar e comparar diferentes modelos de machine learning.

Objetivos desta fase:

- Construir modelos preditivos adequados ao problema (ex.: Logistic Regression, Decision Tree, Random Forest, KNN) ou aplicar regressão, consoante o caso.
- Comparar diferentes abordagens.
- Selecionar o(s) modelo(s) com melhor desempenho.

5. Evaluation

Nesta fase, os formandos devem avaliar criticamente os resultados obtidos e verificar se os modelos respondem ao objetivo do projeto.

Objetivos desta fase:

- Avaliar o desempenho dos modelos.
- Comparar resultados.
- Interpretar os fatores mais relevantes para a previsão.
- Relacionar os resultados com o problema inicial.

As conclusões devem ser apresentadas diretamente no notebook.

Nota: *se o tema escolhido não se adequar a modelação preditiva, o grupo deve, em alternativa, aprofundar a análise exploratória e responder a, pelo menos, três perguntas analíticas com suporte estatístico e gráfico (com validação do formador).*

E. Entregáveis

- Notebooks em Python — um para cada fase de desenvolvimento (ou um notebook único estruturado pelas fases do CRISP-DM).
- Dados brutos recolhidos e conjunto de dados tratado.
- Resultados exportados.
- As análises e conclusões devem ser apresentadas diretamente no notebook, não sendo necessária a entrega de relatório.
- Sugere-se a criação e partilha do repositório do projeto em GitHub (serve de portefólio profissional).

F. Entrega do Projeto

O projeto deve ser entregue numa pasta zipada com todos os ficheiros de suporte.

Data de início	01/09/2026
Data de entrega	18/10/2026
Ficheiro .zip	Incluir todos os ficheiros do projeto
Email para envio	martasmartinho@gmail.com
Assunto do email	CA_AiDAPT04_Grupoxx
Anexo do email	CA_AiDAPT04_Grupoxx.zip

Sugere-se a criação e partilha do repositório do projeto em GitHub (serve de portefólio profissional).